MLDS Homework 3 Report

Model description

Image Generation

我們使用類似原始 DCGAN 的架構：

Generator 一共有四層 transposed convolution layer，channel size 的大小分別為 256、128、64、3，除了最後一層外，每層的輸出都會經過 batch normalization 後通過 SELU 做 activation，最後的一層通過 tanh 做 activation。整個 generator 的輸入是 100 維的 noise ，會先經過線性變換最後轉換成符合輸入的形式 (channel_size, kernel_size, kernel_size)。

Discriminator 則是四層的 convolution layer，channel size 的大小分別為 32、 64、128、256，每層的輸出都會經過 batch normalization 以及 SELU 做 activation，第四層的輸出會被拉平經過現性轉換後過 sigmoid 輸出成一個 scalar。

Text-to-image Generation

我們使用的架構是基於和 3-1 類似的 conditional-DCGAN：

Generator 的部分，hair 以及 eyes 分別以一個數字表示其顏色，兩者分別過一個自己的 embedding layer 變成 5 維，再和 noise 的 100 維 concatenate 後變成 120 維的 input，最後再丟進 3-1 的 generator 架構中。

Discriminator 的部分，hair 以及 eyes 一樣分別過一個自己的 embedding 再 reshape 成(1, 32, 32) 的 1 個 channel 的 tensor，再和 input noise 經過第一個 convolution layer 後的(16, 32, 32) 的 32 個 channel 的 tensor concatenate 在一起變成 (18, 32, 32) 的 18 個 channe l 的 tensor。最後再經過和 3-1 discriminator 後半部一樣的結構。

最後我們還有使用 WGAN 的 clipping 在(-0.02, 0.02)之間防止 mode collapse。

Experiment settings and observation

Image Generation

在實驗的時候，因為我們用的是 DCGAN ，所以要重複的嘗試不同的參數大小，設法讓 Discrminator 與 Generator 的學習過程達到平衡，如果有其中一方太強，Gradient 就會消失。順利的訓練過程如下圖:

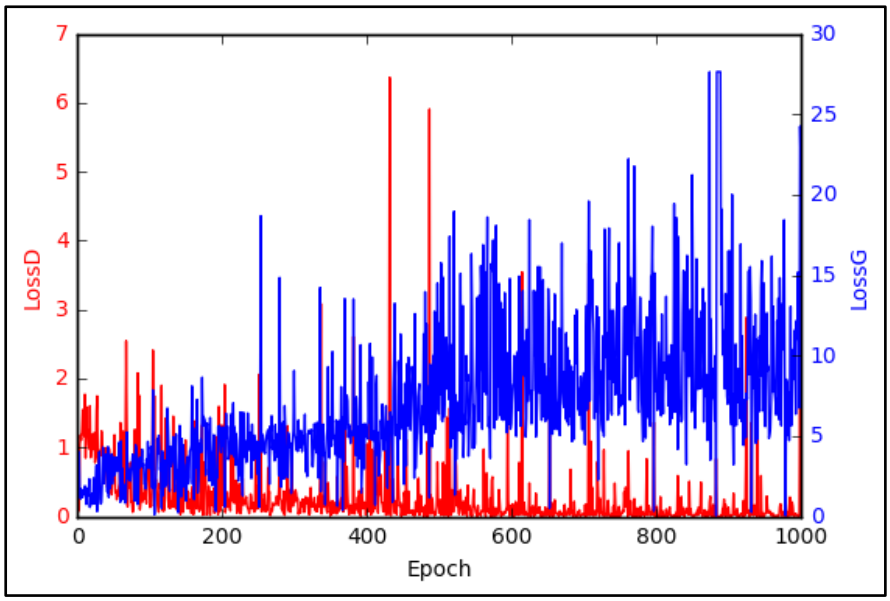

觀察 Generator 輸出的圖像，發現 300 - 500 個 epoch 左右時看起來最佳。而其中第 300 個 epoch 的 dection 結果為 25 張人臉 (下圖左)，儘管如此，還是可以看得出來結果不盡人意，雖然輪廓大致正確，但是眼睛大多不太對稱，且有數張較為模糊。而若是繼續訓練至 1000 個 epoch ， detection 結果為 19 張人臉 (下圖右)，結果會變的較糟，且可以觀察到嚴重的 mode collapse 的現象。

Text-to-image Generation

Training 過程中，與 3-1 的 dcgan 不一樣的地方是，discriminator 還要判斷如果圖片是正確但是敘述是錯誤的也要判斷他是錯的。因此在 discriminator 中，我們 random 取 hair 以及 eyes 的 label，將其與 real images 做 pair 讓 discriminator 判斷。雖然 random 有可能取到和原始 true label 一樣的值，但是其機率大概只有 1/(13 x 11)，因此我們將其忽略。

Generator 我們一開始 embedding 各 50 維再和 noise concatenate，但是如果 embedding 過後的維度太大的話，權重會壓過 noise 造成的差異，很容易導致 mode collapse，因此最後我們 embedding 過後的維度只有 noise 維度的 1/10。另外在處理 mode collapse 上，我們額外時做了 wgan 的 clipping，讓訓練更加穩定。

訓練過程如下圖，可以看出使用 wgan 的 clipping 可以使 generator 以及 discriminator 的

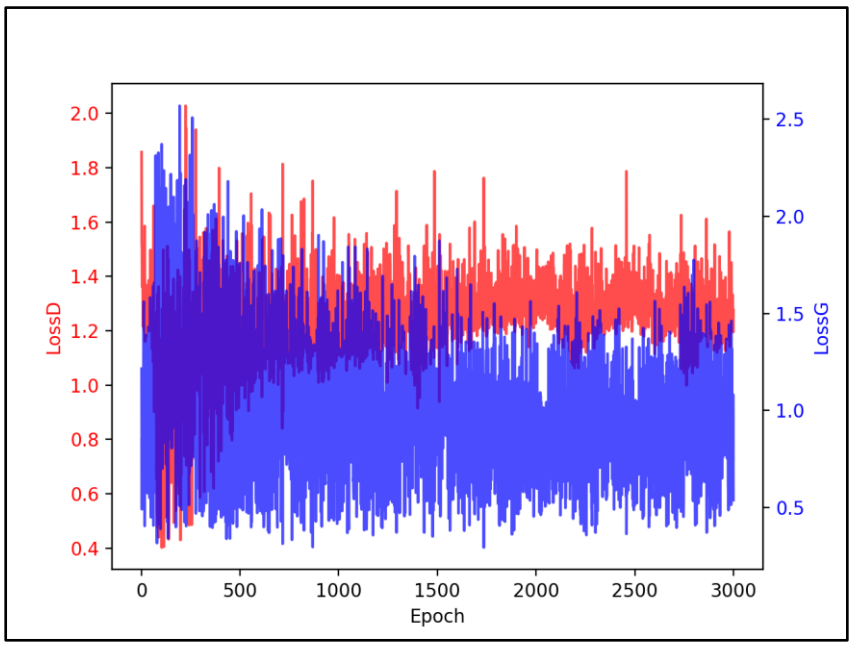

loss 控制在 2 以下，讓訓練更穩定，不會出現 loss 突然暴增的情況。

結果如下圖，由上至下依序為藍髮藍眼、藍髮綠眼、藍髮紅眼、綠髮藍眼、綠髮紅眼。由結果可以看出頭髮以及眼睛 c-dcgan 都能生出正確的顏色，且用 baseline.py 能夠判斷出 25 張臉。即使如此，以肉眼來看臉型扭曲以及眼睛只有生成一隻的情況比第一題的純 dcgan 還要嚴重。我們有試著 noise size 調整至 400、noise sample std 調小至 0.432、增加 generator 或是 discriminator 的 channel 數，結果都如下圖一樣沒辦法產生更清晰的頭像。

Compare DCGAN with WGAN-GP

Image Generation

我們選擇用 WGAN GP 來比較與 DCGAN Image Generation 的結果以及訓練過程，模型的結構大致與 DCGAN 一樣，但是 WGAN GP 需要修改 Discriminator 以及 Generator 的 Loss。我們設置不同的權重 (lambda) 的 gradient penalty ，觀察是否影響訓練。

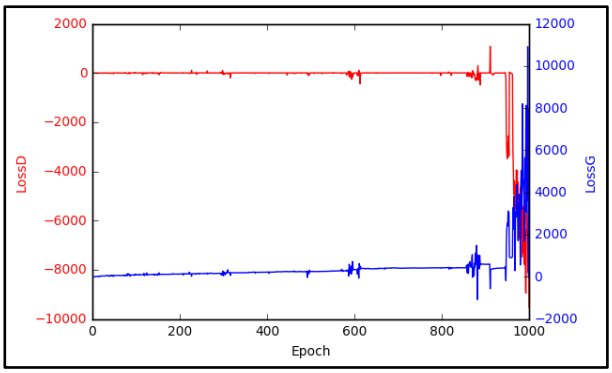

lambda = 1

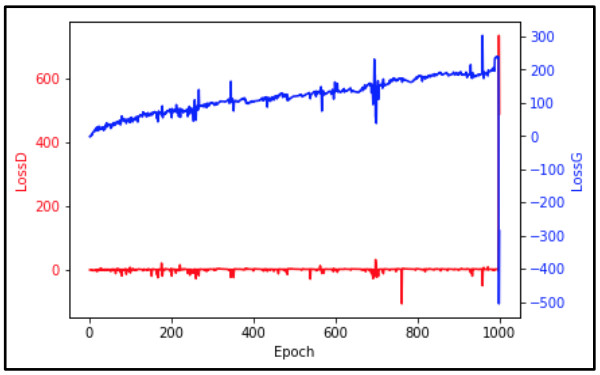

lambda = 10

我們發現在 WGAN GP 的訓練過程中，Generator 的 Loss 會一直持續上升，有可能是因為對抗的過程中，同樣的 Update 次數要讓 Generator 騙過 Discriminator 變得越來越難，因此我們猜測如果把 Generator 的 Update 次數再調高的話可以放緩 Generator Loss 上升的幅度。另外我們也發現，當把 lambda 條高至 10 時，Generator Loss 上升的幅度也會趨緩。總而言之，在訓練過程中，合適的 lambda 可以讓訓練更穩定。但是 WGAN GP 還是會出現 Loss 值劇烈變化的情況，在 lambda = 1 的實驗時 1000 Epoch 時 Dicriminator 的強度遠遠蓋超過 Generator。而 lambda = 10 時則相反。

接著觀察產生出來的圖像，我們取 300 epoch 進行比較:

lambda = 1

lmbda = 10

結果看起來並沒有比 DCGAN 生成的更佳。不過若將第 800 epoch 的結果拿出來比較，WGAN GP 看起來比較沒有 model collapse 的現象，結果如下。

WGAN GP lamda = 10

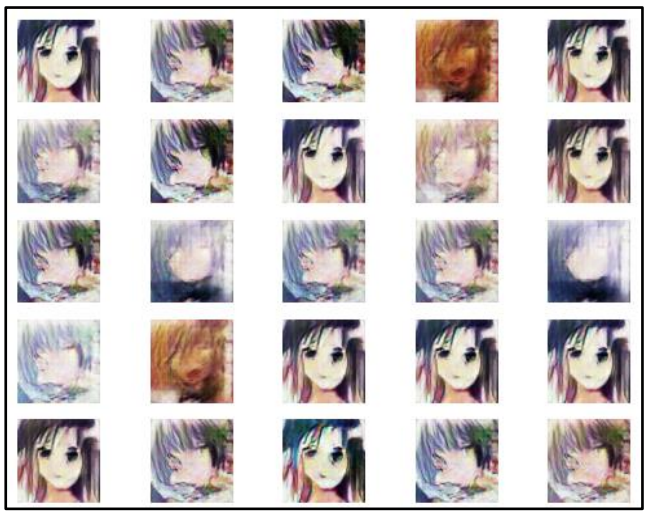

DCGAN

Training tips for improvement

Normalize the Input

我們在 DCGAN 的訓練中有將 0-255 的像素值 normalize 到 -1 至 1 之間，並且使用 Tanh 做為 Generator 最後的 activation function。所以為了觀察沒有 Normalize 的情況，我們做了一次不 normalize 到 -1 至 1 、最後的 activation function 為 relu 的實驗。訓練過程如下圖。

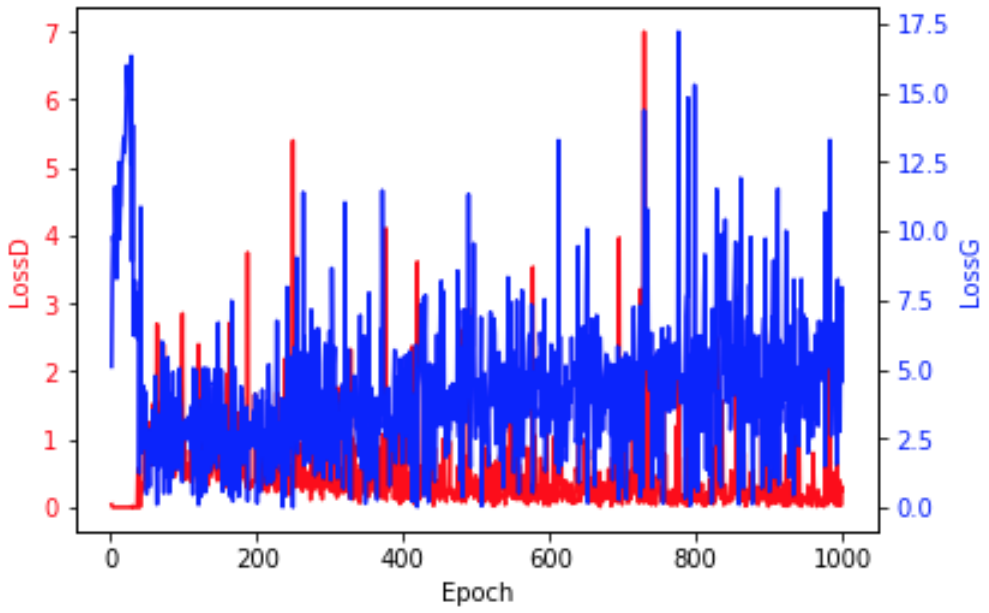

看起來 Generator 與 Dicriminator 都有正常的進行訓練，跟 DCGAN 沒什麼分別，但是實際上把輸出的結果打開來看，不管在哪個 epoch 卻都是一片黑。我們推測會出現這樣的情況可能是雖然 Generator 與 Discriminator 都有在更新但是兩者學習的速度都太慢了。

Use Soft and Noisy Labels

我們的 DCGAN 沒有使用 soft label ，但若用同樣 DCGAN 的架構實驗，真的 label 取樣自 0.7 至 1.2 的值域 ，假的 label 則取樣自 0.0 至 0.3。訓練的結果如下:

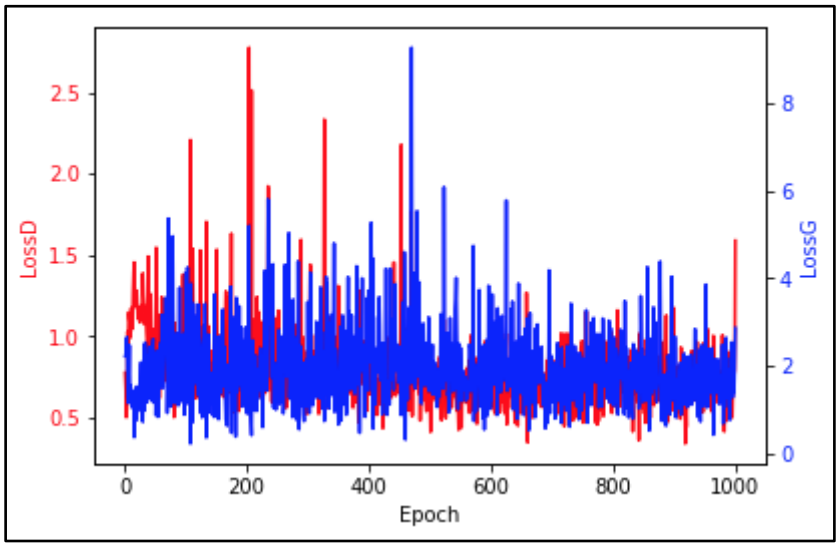

看起來跟原本沒有太大的差別。第 300 epoch 的輸出結果如下，並沒有明顯的進步。

Batch Normalization

我們的 DCGAN 中有使用 Batch Normalization，若將 Generator 以及 Discriminator 中的 Batch Normalization 層全部移除，再進行實驗。訓練的過程如下圖:

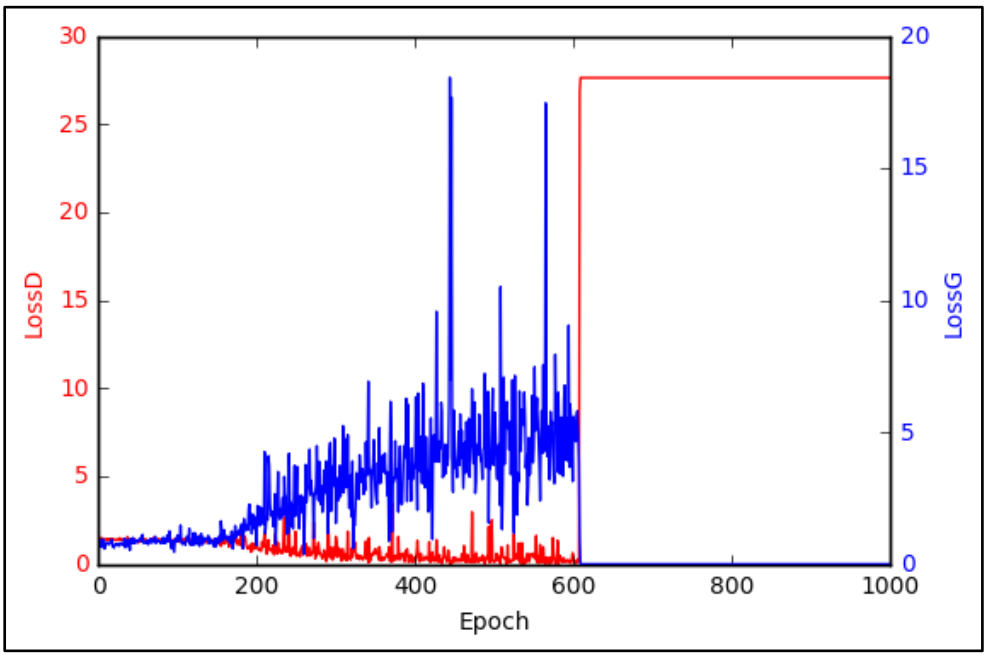

一樣觀察 300 至 500 epoch 的結果，其中第 500 個 epoch 的 detection 結果最好，為 23 張臉 (如下圖) 。圖片品質的差距並沒有很大。不過 600 個 epoch 以後 Generator 的 Loss 就歸零無法再更新了。